وضعیت مصرف سیگار و مدت خواب گزارش‌شده در بزرگسالان آمریکایی

گزارش فاز اول — شناخت مطالعه، داده و آمار توصیفی

درس	آمار و کاربردهای آن — پاییز ۱۴۰۵
دانشجو	محمدیاسین زارع
مسیر پروژه	مسیر الف — NHANES اوت ۲۰۲۱ تا اوت ۲۰۲۳
مخزن کد	`github.com/RealMdyz/Statistics-Project-Fall2026`
برچسب تحویل	`phase-1`

خلاصه

این پروژه رابطه‌ی وضعیت مصرف سیگار (هرگز، سابق، فعلی) با مدت خواب معمول را در بزرگسالان ۱۸ سال و بالاتر آمریکا، با داده‌های پیمایش ملی سلامت و تغذیه‌ی آمریکا (NHANES) در دوره‌ی اوت ۲۰۲۱ تا اوت ۲۰۲۳، بررسی می‌کند. در فاز اول، سه فایل جمعیت‌شناختی، خواب و سیگار با شناسه‌ی `SEQN` ادغام شدند و پس از اعمال سه معیار ورود، نمونه‌ی تحلیلی ۷٬۹۹۶ بزرگسال به دست آمد. کیفیت داده بررسی و برای هر مشکل تصمیم ثبت شد.

به‌طور توصیفی، میانگین هفتگی خواب سیگاری‌های فعلی (۷٫۷۲ ساعت) تنها حدود ۱۴ دقیقه کمتر از افراد هرگز سیگاری (۷٫۹۵ ساعت) است، اما سهم «خواب کوتاه» (کمتر از ۷ ساعت) در سیگاری‌های فعلی ۲۷٫۷٪ و در هرگز سیگاری‌ها ۱۶٫۸٪ است (برآورد وزن‌دار)؛ یعنی حدود ۱۱ واحد درصد تفاوت. گروه‌های سیگار از نظر سن و جنسیت با یکدیگر متفاوت‌اند؛ بنابراین این تفاوت‌ها خام و صرفاً توصیفی‌اند و هیچ ادعای استنباطی یا علّی در این فاز مطرح نمی‌شود.

۱. مقدمه و سؤال پژوهش

خواب کافی و مصرف دخانیات هر دو از عوامل مهم سلامت عمومی‌اند. نیکوتین یک ماده‌ی محرک است و مصرف سیگار ممکن است با الگوی خواب ارتباط داشته باشد. هدف این پروژه توصیف و سپس بررسی آماری این ارتباط در یک نمونه‌ی ملی است.

> **سؤال آماری اصلی:** آیا مدت خواب معمول در بزرگسالان ۱۸ سال و بالاتر آمریکا میان افراد هرگز سیگاری، سیگاری سابق و سیگاری فعلی تفاوت دارد، و آیا این رابطه پس از در نظر گرفتن سن و جنسیت باقی می‌ماند؟

نوع سؤال: مقایسه‌ای (مقایسه‌ی خواب در سه گروه) و ارتباطی (رابطه‌ی شدت مصرف با خواب، با کنترل سن و جنسیت). سؤال پیش‌بینی‌محور یا علّی نیست.

فرضیه‌ی اولیه: سیگاری‌های فعلی نسبت به افراد هرگز سیگاری، خواب معمول کوتاه‌تر و سهم بیشتری از خواب کوتاه گزارش می‌کنند و سیگاری‌های سابق در میانه قرار می‌گیرند. فرض صفر و مقابل به‌صورت رسمی در فاز سوم نوشته می‌شوند.

۲. منشأ داده و سازوکار جمع‌آوری (تسک ۱)

NHANES یک پیمایش ملی سلامت است که مرکز ملی آمار سلامت آمریکا (NCHS)، زیرمجموعه‌ی مراکز کنترل و پیشگیری بیماری (CDC)، اجرا می‌کند. هدف آن برآورد وضعیت سلامت و تغذیه‌ی جمعیت غیرنظامیِ ساکن در خانوارهای آمریکاست. دوره‌ی اوت ۲۰۲۱ تا اوت ۲۰۲۳ نخستین انتشار ملی پس از توقف ناشی از همه‌گیری کروناست.

هر شرکت‌کننده سه مرحله را طی می‌کند: **مصاحبه‌ی خانگی** (پرسش‌نامه‌های جمعیت‌شناختی، سلامت و سبک زندگی)، **معاینه در مرکز معاینه‌ی سیار** (MEC؛ اندازه‌گیری‌های بدنی و فشار خون) و **آزمایش‌های آزمایشگاهی**. هر دو متغیر اصلی

این پروژه، یعنی خواب و سیگار، از پرسش‌نامه‌ی مصاحبه‌ی خانگی می‌آیند و **خوداظهاری**‌اند.

داده‌ها عمومی‌اند و از صفحه‌ی رسمی CDC در تاریخ ۱۲ اکتبر ۲۰۲۶ (۲۰ مهر ۱۴۰۵) با اسکریپت `src/download_data.py` دریافت شدند. سه فایل استفاده‌شده:

فایل	بخش	تعداد ردیف	کاربرد در پروژه
`DEMO_L`	جمعیت‌شناختی	11,933	سن، جنسیت، وزن‌ها و متغیرهای طرح نمونه‌گیری
`SLQ_L`	پرسش‌نامه‌ی خواب (۱۶ سال+)	8,501	ساعت خواب روزهای کاری و تعطیل
`SMQ_L`	پرسش‌نامه‌ی سیگار (۱۲ سال+)	9,015	وضعیت مصرف و تعداد نخ در روز

نوع مطالعه: این داده حاصل یک **پیمایش مقطعی و مشاهده‌ای** است. هیچ مداخله‌ای روی افراد انجام نشده و هر فرد تنها یک بار مشاهده شده است. بنابراین داده‌ها می‌توانند ارتباط میان متغیرها را نشان دهند، اما برای اثبات رابطه‌ی علّی یا تعیین جهت رابطه کافی نیستند.

۳. طرح نمونه‌گیری، وزن‌ها و قابلیت تعمیم (تسک ۳ و الف.۲)

NHANES نمونه‌ی تصادفی ساده نیست. نمونه با یک طرح **چندمرحله‌ای، لایه‌بندی‌شده و خوشه‌ای** انتخاب می‌شود: ابتدا واحدهای نمونه‌گیری اولیه (معمولاً شهرستان‌ها؛ ۳۰ واحد در این دوره) و سپس به‌ترتیب محله‌ها، خانوارها و افراد. در مرحله‌ی آخر، همه‌ی افراد زیر ۲۰ سال و بالای ۶۰ سالِ خانوار انتخاب می‌شوند، اما از بزرگسالان ۲۰ تا ۵۹ سال فقط یک یا دو نفر. در این دوره، نمونه‌گیری مازاد بر اساس نژاد و درآمد نیز حذف شده است.

پیامد: احتمال انتخاب شدن برای همه یکسان نیست؛ مثلاً سالمندان بیش از سهم واقعی‌شان در نمونه حضور دارند (۴۲٫۸٪ نمونه‌ی تحلیلی ما ۶۰ سال و بالاترند، در حالی که برآورد وزن‌دار این سهم ۳۰٪ است).

وزن نمونه‌گیری

هر شرکت‌کننده یک **وزن نمونه‌گیری** دارد که نشان می‌دهد نماینده‌ی چند نفر از جمعیت آمریکاست. وزن، احتمال انتخاب نابرابر را جبران می‌کند و اثر عدم پاسخ را تا حدی تعدیل می‌کند. مجموع وزن‌های مصاحبه‌ی همه‌ی ۱۱,۹۳۳ شرکت‌کننده حدود ۳۲۷ میلیون است که تقریباً برابر جمعیت هدف آمریکاست. وزن‌ها از حدود ۴,۶۰۰ تا ۱۷۱,۰۰۰ متغیرند.

انتخاب وزن: طبق راهنمای NHANES، باید وزن «کوچک‌ترین زیرجمعیتی» را به کار برد که همه‌ی متغیرهای تحلیل را دارد. چون هر دو متغیر اصلی از مصاحبه‌ی خانگی‌اند و از معاینه یا آزمایش استفاده نمی‌کنیم، **وزن مصاحبه (`WTINT2YR`)** انتخاب شد. برآورد میانگین یا نسبت وزن‌دار به‌صورت $\Sigma(w_i \cdot x_i) \,/\, \Sigma w_i$ محاسبه می‌شود.

لایه و خوشه: متغیرهای `SDMVSTRA` (لایه‌ی ساختگی) و `SDMVPSU` (خوشه‌ی ساختگی) ساختار طرح را نشان می‌دهند. افراد یک خوشه به هم شبیه‌ترند، پس نادیده گرفتن طرح، خطای استاندارد را کمتر از واقع نشان می‌دهد. این متغیرها در فاز اول (توصیفی) لازم نیستند و در فاز سوم برای فاصله‌ی اطمینان به کار می‌روند.

قابلیت تعمیم

- نتایج **وزن‌دار** به جمعیت غیرنظامیِ ساکن در خانوارِ ۱۸ سال و بالاتر آمریکا در سال‌های ۲۰۲۱ تا ۲۰۲۳ قابل تعمیم‌اند؛ نتایج بدون وزن فقط نمونه را توصیف می‌کنند.
- **نرخ پاسخ** این دوره پایین است (حدود ۳۵٪ برای مصاحبه و حدود ۲۶٪ برای معاینه، در مقایسه با حدود ۵۱٪ و ۴۷٪ در دوره‌ی قبل). وزن‌ها بخشی از این مشکل را جبران می‌کنند، اما احتمال سوگیری ناشی از عدم پاسخ باقی است.
- بین فروردین ۲۰۲۰ (آوریل) و تیر ۲۰۲۱ (ژوئیه) داده‌ای جمع نشده است و نتایج به معنای دقیق به دوره‌ی همه‌گیری قابل تعمیم نیستند.
- نتایج به جمعیت ایران یا کشورهای دیگر قابل تعمیم مستقیم نیستند.

۴. واحد مشاهده و متغیرها (تسک ۲ و ۴)

واحد مشاهده: هر ردیف یک شرکت‌کننده است. در هر سه فایل، تعداد ردیف‌ها با تعداد شناسه‌های یکتای `SEQN` برابر است؛ یعنی هیچ فردی بیش از یک ردیف ندارد و ساختار تکرارشونده یا سلسله‌مراتبی وجود ندارد.

جدول ۱ — متغیرهای اصلی و مقیاس اندازه‌گیری

متغیر	نام در NHANES	نوع	نقش
ساعت خواب روزهای کاری	`SLD012`	کمی پیوسته (گام ۰٫۵ ساعت)	سازنده‌ی متغیر پاسخ
ساعت خواب روزهای تعطیل	`SLD013`	کمی پیوسته (گام ۰٫۵ ساعت)	سازنده‌ی متغیر پاسخ
میانگین هفتگی خواب	(۵× `SLD012` + ۲× `SLD013`) ÷ ۷	کمی پیوسته	**متغیر پاسخ اصلی**
خواب کوتاه	میانگین هفتگی کمتر از ۷ ساعت	دودویی	نسخه‌ی دودویی پاسخ
مصرف دست‌کم ۱۰۰ نخ در عمر	`SMQ020`	دودویی	سازنده‌ی گروه سیگار
مصرف فعلی سیگار	`SMQ040`	اسمی (هر روز / بعضی روزها / اصلاً)	سازنده‌ی گروه سیگار
وضعیت سیگار	ترکیب دو متغیر بالا	اسمی سه‌سطحی	**متغیر گروه‌بندی اصلی**
تعداد نخ در روز	`SMD650`	کمی گسسته	شدت مصرف (فقط سیگاری‌های فعلی)
سن	`RIDAGEYR`	کمی (سقف ۸۰ سال)	متغیر تعدیل
جنسیت	`RIAGENDR`	دودویی	متغیر تعدیل

وزن مصاحبه	WTINT2YR	وزن نمونه‌گیری	تعمیم به جمعیت

تعریف گروه‌های سیگار: «هرگز سیگاری» = SMQ020 برابر «خیر»؛ «سیگاری سابق» = SMQ020 برابر «بله» و SMQ040 برابر «اصلاً»؛ «سیگاری فعلی» = SMQ020 برابر «بله» و SMQ040 برابر «هر روز» یا «بعضی روزها».

دلیل میانگین هفتگی: هفته پنج روز کاری و دو روز تعطیل دارد؛ میانگین ساده‌ی دو مقدار، وزن برابر به این دو نوع روز می‌داد. تفاوت خواب روز کاری و تعطیل نیز برای بسیاری از افراد صفر نیست (میانگین تفاوت حدود نیم ساعت).

دلیل آستانه‌ی ۷ ساعت: آکادمی پزشکی خواب آمریکا و انجمن پژوهش خواب حداقل ۷ ساعت خواب را برای بزرگسالان توصیه می‌کنند و CDC نیز کمتر از ۷ ساعت را «خواب کوتاه» تعریف می‌کند. این آستانه پیش از مشاهده‌ی نتایج تعیین شد.

۵. ادغام فایل‌ها و جمعیت تحلیلی (تسک الف.۱ و الف.۴)

سه فایل با کلید SEQN و روش **left join** ادغام شدند و DEMO_L پایه قرار گرفت، چون همه‌ی شرکت‌کنندگان و وزن‌ها در آن هستند. با این روش هیچ فردی در مرحله‌ی ادغام به‌طور ضمنی حذف نمی‌شود و همه‌ی حذف‌ها بعداً به‌صورت آگاهانه و قابل ردیابی انجام می‌شوند. تعداد ردیف‌ها پیش و پس از ادغام برابر بود (۱۱,۹۳۳)، و بررسی validate="one_to_one" تأیید کرد که شناسه‌ی تکراری وجود ندارد.

جدول ۲ — معیارهای ورود و تعداد افراد در هر مرحله (به ترتیب اعمال)

مرحله	باقی‌مانده	حذف‌شده	دلیل حذف
همه‌ی شرکت‌کنندگان NHANES ۲۰۲۱–۲۰۲۳	11,933	—	—
۱. سن ۱۸ سال و بالاتر	8,153	3,780	پرسش‌های اصلی سیگار فقط از ۱۸ سال+ پرسیده می‌شوند
۲. وضعیت سیگار معتبر	8,121	32	۱۴ نفر «جواب نداد/نمی‌داند» و ۱۸ نفر بدون پاسخ در SMQ020
۳. هر دو مقدار خواب موجود	7,996	125	میانگین هفتگی خواب قابل محاسبه نیست
نمونه‌ی تحلیلی نهایی	**7,996**	**3,937**	**—**

ترتیب مراحل اهمیت دارد: ۱۴۲ بزرگسال داده‌ی خواب ناقص داشتند، اما ۱۷ نفر از آن‌ها پیش‌تر در مرحله‌ی ۲ حذف شده بودند. در مجموع تنها ۱۵۷ بزرگسال (۱٫۹٪ از ۸,۱۵۳ نفر) به دلیل داده‌ی ناقص کنار گذاشته شدند. این افراد به‌طور میانگین کمی مسن‌تر (۵۶٫۶ در برابر ۵۲٫۱ سال) و با سهم مردان بیشتر (۵۴٪ در برابر ۴۵٪) بودند؛ بنابراین حذف کاملاً تصادفی نبوده، اما به دلیل تعداد کم، اثر آن بر نتایج احتمالاً ناچیز است.

۶. بررسی کیفیت داده (تسک ۵)

کیفیت داده روی همه‌ی ۸,۱۵۳ بزرگسال بررسی شد. نکته‌ی کلیدی تفکیک «پرسیده نشده» از «واقعاً گمشده» است: مثلاً `SMQ040` برای ۶۰٪ بزرگسالان خالی است، اما همه‌ی این موارد نتیجه‌ی **پرش طبیعی پرسش‌نامه**‌اند (این پرسش فقط از کسانی پرسیده می‌شود که به `SMQ020` پاسخ «بله» داده‌اند) و هیچ مورد واقعاً گمشده‌ای وجود ندارد. همچنین کدهای ویژه (۷، ۹، ۷۷۷، ۹۹۹) عدد ثبت شده‌اند و با بررسی ساده‌ی خانه‌های خالی شناسایی نمی‌شوند؛ این کدها جداگانه بررسی شدند.

جدول ۳ — مشکلات کیفیت داده و تصمیم‌ها

مورد	تعداد	تصمیم	دلیل
شناسه‌ی تکراری `SEQN`	0	—	هر فرد یک بار آمده است
مقادیر خارج از محدوده (سن، جنسیت، وزن، خواب)	0	—	همه در محدوده‌ی مستندات
خواب کاری یا تعطیل گمشده	142	حذف	متغیر پاسخ قابل محاسبه نیست
`SMQ020` جواب نداد (۷) / نمی‌داند (۹)	14	حذف	گروه سیگار قابل تعیین نیست
`SMQ020` خالی	18	حذف	گروه سیگار قابل تعیین نیست
`SMQ040` خالی چون `SMQ020` = خیر	4,878	گمشده نیست؛ «هرگز سیگاری»	پرش طبیعی پرسش‌نامه
خواب با کد ۲ (کمتر از ۳ ساعت) یا ۱۴ (۱۴ ساعت+)	104	نگه‌داری و علامت‌گذاری	اطلاعات معتبر از خواب بسیار کم یا زیاد؛ حذف آن‌ها سوگیری ایجاد می‌کرد. تحلیل حساسیت در فاز پنجم
`SMD650` = ۷۷۷ / ۹۹۹	9	تبدیل به گمشده	تعداد واقعی نخ نیست
سیگاری «بعضی روزها» بدون تعداد نخ	15	نگه‌داری در گروه فعلی	۱۰ نفر در ۳۰ روز گذشته سیگار نکشیده و ۵ نفر «نمی‌داند» گفته‌اند؛ پرسش تعداد نخ از آن‌ها پرسیده نشده
اختلاف خواب کاری و تعطیل ≤ ۸ ساعت	19	نگه‌داری	از نظر منطقی ممکن (مثلاً کار شیفتی)؛ شاهدی بر خطا نیست
سن ۸۰ (سقف کدگذاری)	508	نگه‌داری	سن واقعی بالای ۸۰ نامعلوم؛ محدودیت ثبت شد

اهمیت کدهای ویژه در یک مثال روشن است: میانگین خام `SMD650` با احتساب کد ۹۹۹ برابر ۱۹٫۱ نخ است، اما پس از تبدیل این کدها به گمشده به ۱۱٫۶ نخ کاهش می‌یابد؛ یعنی تنها ۹ مقدار نادرست، میانگین را حدود ۶۵٪ بالا می‌برد.

سازگاری منطقی: هیچ فرد «هرگز سیگاری» یا «سابق» تعداد نخ ثبت‌شده ندارد و همه‌ی سیگاری‌های روزانه تعداد نخ دارند. جدول توافقی `SMQ020` و `SMQ040` نشان داد که منطق پرش پرسش‌ها در داده رعایت شده است.

۷. آمار توصیفی (تسک ۶ و ۷)

۷.۱ جدول‌های فراوانی

جدول ۴ — توزیع متغیرهای طبقه‌ای در نمونه‌ی تحلیلی (n = 7,996)

متغیر	سطح	تعداد	درصد نمونه	درصد وزن‌دار
وضعیت سیگار	هرگز	4,823	60.3	63.0
	سابق	2,020	25.3	22.9
	فعلی	1,153	14.4	14.1
جنسیت	مرد	3,572	44.7	48.3
	زن	4,424	55.3	51.7
خواب کوتاه	بله (کمتر از ۷ ساعت)	1,595	19.9	19.1
	خیر	6,401	80.1	80.9

حدود ۱۴٪ بزرگسالان سیگاری فعلی‌اند و حدود یک‌پنجم آن‌ها خواب کوتاه گزارش کرده‌اند. زنان در نمونه کمی بیش از سهم واقعی‌شان حضور دارند و وزن‌دهی این را اصلاح می‌کند.

۷.۲ مرکز و پراکندگی

جدول ۵ — خلاصه‌ی متغیرهای کمی

متغیر	n	میانگین	انحراف معیار	میانه	Q1	Q3	IQR	چولگی
میانگین هفتگی خواب (ساعت)	7,996	7.90	1.51	8.00	7.00	8.71	1.71	-0.06
خواب روز کاری (ساعت)	7,996	7.74	1.62	8.00	7.00	8.50	1.50	0.02
خواب روز تعطیل (ساعت)	7,996	8.30	1.72	8.00	7.50	9.00	1.50	-0.11
سن (سال)	7,996	52.06	18.56	55.00	36.00	68.00	32.00	-0.23
نخ در روز (سیگاری‌های فعلی)	1,132	11.51	9.92	10.00	5.00	18.50	13.50	2.53

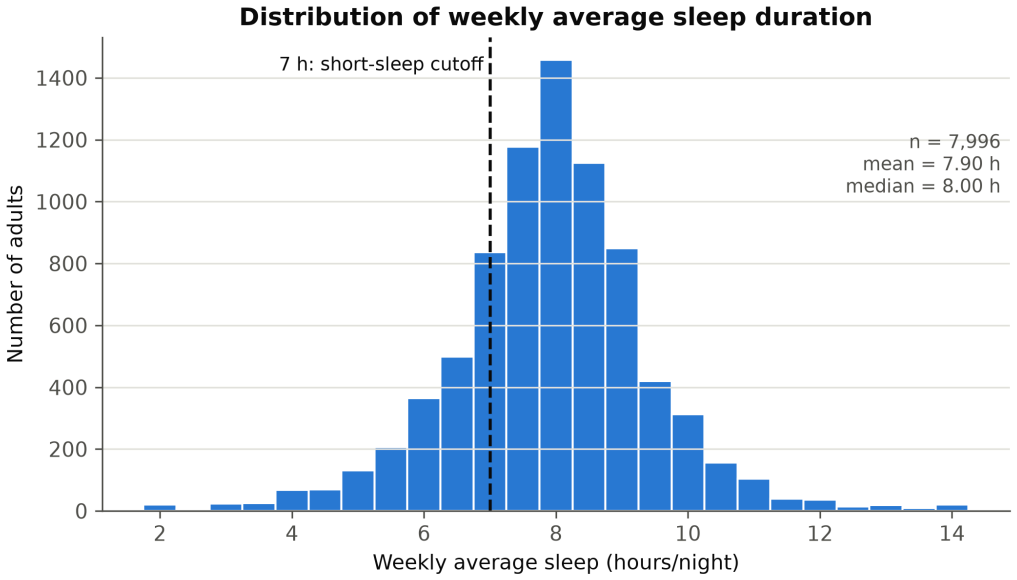
انتخاب معیار مناسب:

- **خواب هفتگی:** چولگی نزدیک صفر است و میانگین (۷٫۹۰) و میانه (۸٫۰۰) نزدیک‌اند؛ پس میانگین و انحراف معیار مناسب‌اند. چون کدهای ۲ و ۱۴ دنباله‌های بلندی ایجاد می‌کنند، میانه و IQR نیز گزارش می‌شوند.
- **سن:** تقریباً متقارن است؛ میانگین و انحراف معیار مناسب‌اند، با این توجه که سقف ۸۰ سال سمت راست توزیع را بریده است.

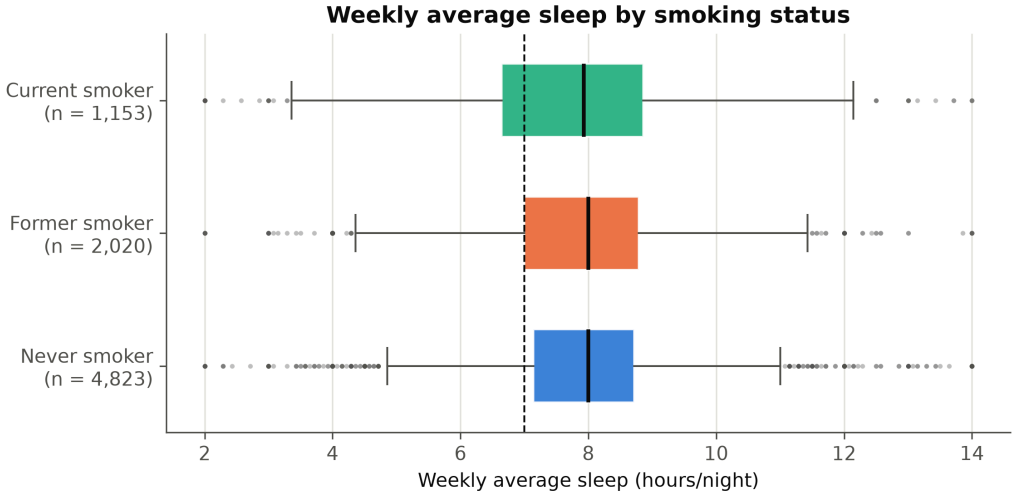
- **تعداد نخ در روز:** به‌شدت چوله به راست است (چولگی ۲٫۵)؛ چند نفر با مصرف بسیار بالا (تا ۹۵ نخ) میانگین را بالا می‌کشند. **میانه (۱۰ نخ) و IQR** خلاصه‌ی مناسب‌تری هستند.

۸. نمودارها و مقایسه‌ی توصیفی گروه‌ها (تسک ۸ و ۹)

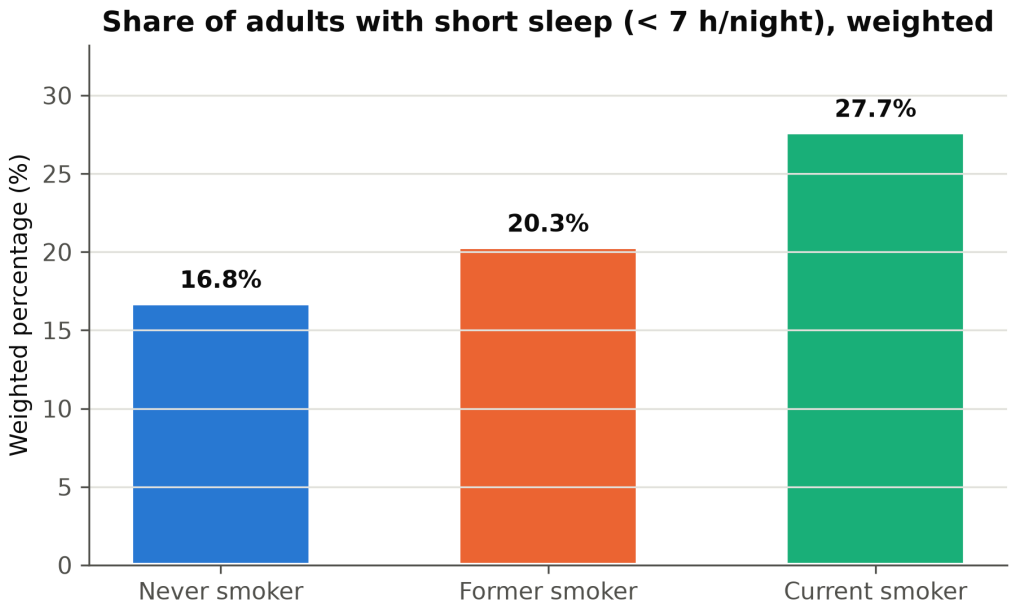
در همه‌ی نمودارها هر گروه سیگار رنگ ثابتی دارد (هرگز: آبی، سابق: نارنجی، فعلی: سبزآبی). نوع نمودار متناسب با نوع متغیر انتخاب شده است: هیستوگرام برای توزیع یک متغیر کمی، نمودار جعبه‌ای برای مقایسه‌ی متغیر کمی در چند گروه و نمودار میله‌ای برای نسبت‌ها.



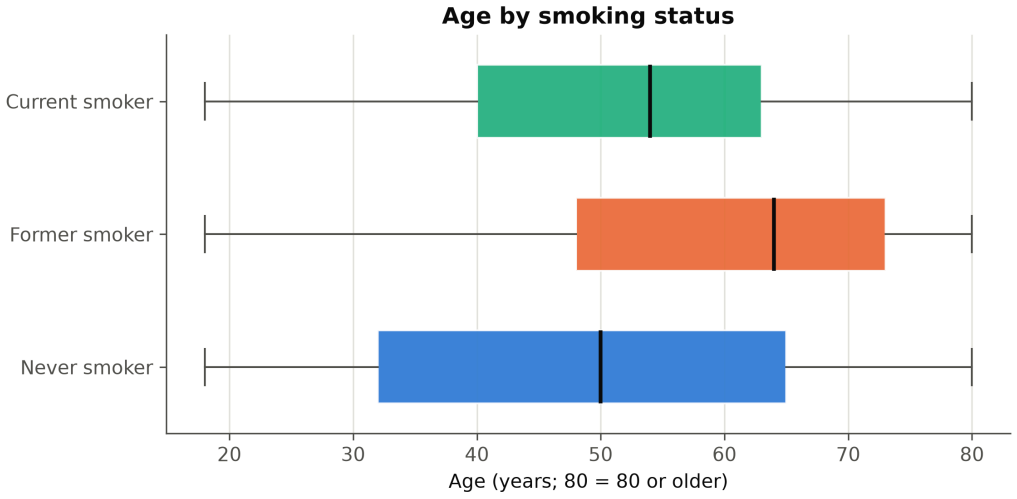
شکل ۱ — توزیع میانگین هفتگی خواب. بیشتر بزرگسالان بین ۷ تا ۹ ساعت می‌خوابند و قله‌ی توزیع حدود ۸ ساعت است. توزیع تقریباً متقارن است، اما دنباله‌ی چپ (خواب بسیار کوتاه) و چند مقدار در کد سقف ۱۴ ساعت دیده می‌شود.



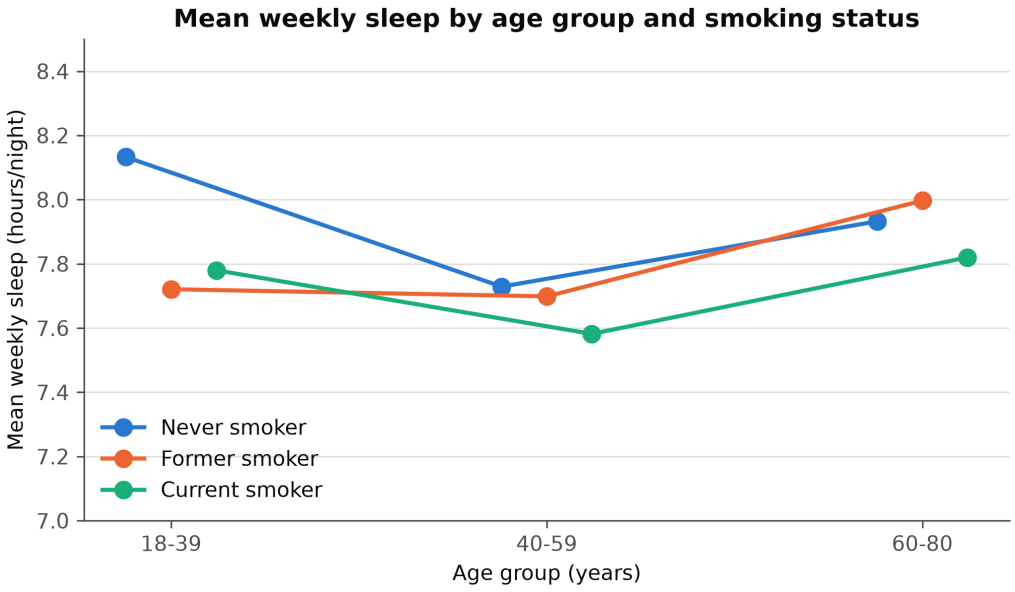
شکل ۲ — میانگین هفتگی خواب به تفکیک وضعیت سیگار (خط سیاه: میانه؛ جعبه: چارک اول تا سوم؛ خط‌چین: آستانه‌ی ۷ ساعت). میانه‌ی هر سه گروه حدود ۸ ساعت است، اما جعبه‌ی سیگاری‌های فعلی پهن‌تر و به سمت خواب کمتر کشیده شده است (چارک اول ۶٫۶ در برابر ۷٫۱ ساعت برای هرگز سیگاری‌ها).



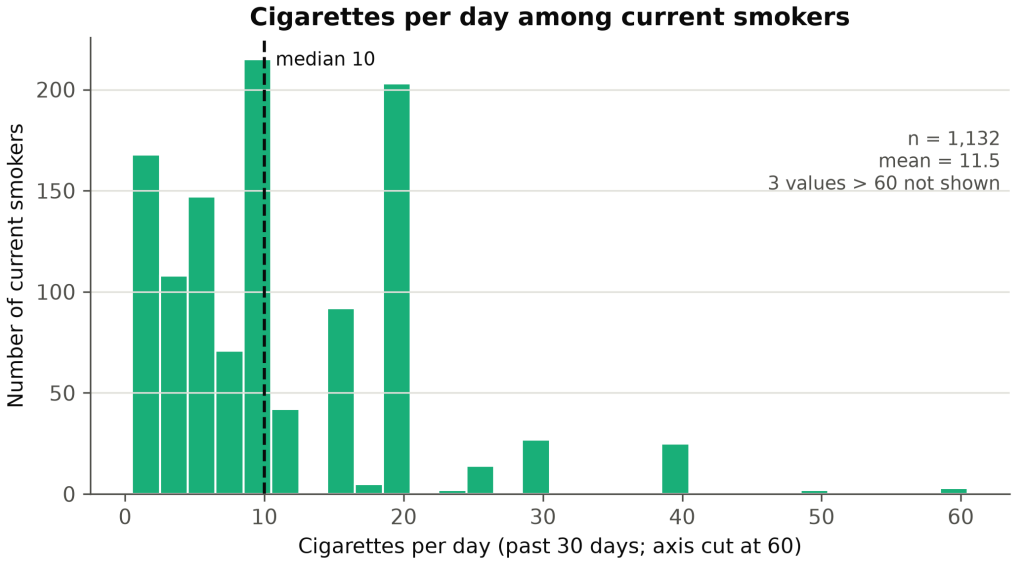
شکل ۳ — سهم وزن‌دار خواب کوتاه در هر گروه. سهم خواب کوتاه با حرکت از هرگز سیگاری (۱۶٫۸٪) به سابق (۲۰٫۳٪) و فعلی (۲۷٫۷٪) افزایش می‌یابد.



شکل ۴ — سن به تفکیک وضعیت سیگار. سیگاری‌های سابق به‌طور واضح مسن‌ترند. چون گروه‌ها از نظر سنی متفاوت‌اند، سن می‌تواند در مقایسه‌ی خواب گروه‌ها مخدوش‌کننده باشد.



شکل ۵ — میانگین خواب به تفکیک گروه سنی و وضعیت سیگار (محور عمودی از ۷ ساعت شروع می‌شود). در هر سه گروه سنی، سیگاری‌های فعلی کمتر از هرگز سیگاری‌ها می‌خوابند؛ پس این تفاوت صرفاً ناشی از تفاوت سنی نیست. مقایسه با سیگاری‌های سابق یکدست نیست: در گروه ۱۸ تا ۳۹ سال، سیگاری‌های سابق کمی کمتر از سیگاری‌های فعلی می‌خوابند. گروه سنی ۴۰ تا ۵۹ سال در همه‌ی گروه‌ها کمترین خواب را دارد.



شکل ۶ — تعداد نخ در روز در سیگاری‌های فعلی. توزیع به‌شدت چوله به راست است. قله‌های ۱۰ و ۲۰ نخ احتمالاً ناشی از گرد کردن پاسخ‌ها («نیم پاکت»، «یک پاکت») است که یک نکته‌ی کیفیت اندازه‌گیری به شمار می‌رود.

مقایسه‌ی توصیفی سه گروه

جدول ۶ — مقایسه‌ی توصیفی گروه‌های سیگار (بدون ادعای استنباطی)

شاخص	هرگز	سابق	فعلی
تعداد	4,823	2,020	1,153

میانگین خواب هفتگی (ساعت)	7.95	7.88	7.72
انحراف معیار خواب	1.43	1.53	1.77
میانه‌ی خواب	8.00	8.00	7.93
چارک اول تا سوم خواب	7.14 – 8.71	7.00 – 8.79	6.64 – 8.86
خواب کوتاه (٪، نمونه)	17.9	20.1	28.2
خواب کوتاه (٪، وزن‌دار)	16.8	20.3	27.7
میانگین سن (سال)	48.9	59.9	51.5
مردان (٪)	39.6	51.9	53.2

جمع‌بندی توصیفی: میانگین خواب سیگاری‌های فعلی تنها حدود ۱۴ دقیقه کمتر از هرگز سیگاری‌هاست، اما سهم خواب کوتاه در آن‌ها حدود ۱۱ واحد درصد بیشتر است (۲۷٫۷٪ در برابر ۱۶٫۸٪ وزن‌دار؛ یعنی حدود ۶۵٪ بیشتر به‌صورت نسبی). انحراف معیار خواب نیز در سیگاری‌های فعلی بیشتر است؛ یعنی تفاوت اصلی در **پراکندگی و دنباله‌ی پایینی توزیع** است، نه در مرکز آن. گروه‌ها از نظر سن و جنسیت متفاوت‌اند و این تفاوت‌ها خام‌اند؛ هیچ آزمون آماری انجام نشده و نتیجه‌ی علّی گرفته نمی‌شود.

۹. خلاصه‌ی ساده در برابر وزن‌دار (تسک الف.۳)

جدول ۷ — مقایسه‌ی برآوردهای بدون وزن (توصیف نمونه) و وزن‌دار (برآورد جمعیت)

کمیت	بدون وزن	وزن‌دار	تفاوت
میانگین هفتگی خواب (ساعت)	7.90	7.90	0.00
میانه‌ی هفتگی خواب (ساعت)	8.00	8.00	0.00
خواب کوتاه (٪)	19.95	19.11	-0.83
سیگاری فعلی (٪)	14.42	14.08	-0.34
میانگین سن (سال)	52.06	47.72	-4.33
۶۰ سال و بالاتر (٪)	42.83	30.00	-12.83

- **سن بیشترین تغییر را دارد:** میانگین سن نمونه حدود ۵۲ سال است اما برآورد وزن‌دار حدود ۴۸ سال، و سهم ۶۰ ساله‌ها و بالاتر از ۴۳٪ به ۳۰٪ کاهش می‌یابد. دلیل آن طرح نمونه‌گیری است که سالمندان را بیش از سهمشان انتخاب کرده است؛ وزن‌ها این را اصلاح می‌کنند.

- **خواب تقریباً تغییر نمی‌کند:** چون مدت خواب در گروه‌های سنی تفاوت زیادی ندارد، اصلاح سهم سنی، میانگین و میانه‌ی خواب را تغییر نمی‌دهد. سهم خواب کوتاه کمی کاهش می‌یابد.
- **درس این مقایسه:** اینکه وزن‌دهی یک برآورد را تغییر دهد یا نه، به میزان ارتباط آن متغیر با ویژگی‌هایی بستگی دارد که نمونه‌گیری بر اساس آن‌ها نابرابر بوده است. برای ادعا درباره‌ی جمعیت آمریکا، برآوردهای وزن‌دار مبنا قرار می‌گیرند.

۱۰. سؤال نهایی، محدودیت‌ها و گام‌های بعدی (تسک ۱۰)

سؤال نهایی

شناخت داده‌ها نشان داد که سؤال اولیه با این داده قابل پاسخ است و نیازی به تغییر آن نیست. سه دلیل: (۱) هر دو متغیر اصلی برای ۹۸٪ بزرگسالان در دسترس‌اند؛ (۲) هر سه گروه سیگار حجم نمونه‌ی کافی دارند (کوچک‌ترین گروه ۱,۱۵۳ نفر)؛ (۳) متغیرهای تعدیل (سن و جنسیت) کامل‌اند. بر اساس یافته‌های توصیفی، سؤال با دقت بیشتری این‌گونه نهایی می‌شود:

> در بزرگسالان ۱۸ سال و بالاتر آمریکا (NHANES ۲۰۲۱–۲۰۲۳)، آیا **میانگین هفتگی خواب** و **سهم خواب کوتاه (کمتر از ۷ ساعت)** میان افراد هرگز سیگاری، سیگاری سابق و سیگاری فعلی تفاوت دارد؟ آیا این تفاوت پس از در نظر گرفتن سن و جنسیت باقی می‌ماند؟ و آیا در میان سیگاری‌های فعلی، تعداد نخ در روز با مدت خواب مرتبط است؟

افزودن «سهم خواب کوتاه» به سؤال، از این یافته‌ی توصیفی ناشی می‌شود که تفاوت گروه‌ها بیشتر در دنباله‌ی پایینی توزیع است تا در میانگین. این پرسش از ابتدا در کارت پروژه به‌عنوان نسخه‌ی دودویی پاسخ تعریف شده بود.

محدودیت‌ها

1. **خوداظهاری:** خواب و سیگار هر دو خوداظهاری‌اند. مدت خواب از ساعت معمول خوابیدن و بیدار شدن محاسبه شده و زمان در رختخواب را نشان می‌دهد، نه خواب واقعی؛ بنابراین احتمالاً خواب واقعی را بیش از حد برآورد می‌کند.
2. **طرح مقطعی و مشاهده‌ای:** جهت رابطه نامعلوم است (ممکن است سیگار بر خواب اثر بگذارد یا کم‌خوابی با مصرف بیشتر همراه شود) و عوامل مخدوش‌کننده‌ای مانند استرس، افسردگی، مصرف الکل یا کار شیفتی ممکن است بخشی از رابطه را توضیح دهند.
3. **نرخ پاسخ پایین** این دوره (حدود ۳۵٪ برای مصاحبه) که حتی با وزن‌دهی احتمال سوگیری عدم پاسخ را باقی می‌گذارد.
4. **محدودیت کدگذاری:** خواب کمتر از ۳ ساعت و ۱۴ ساعت یا بیشتر در کدهای ۲ و ۱۴ ادغام شده‌اند و سن بالای ۸۰ سال با ۸۰ ثبت شده است.
5. **حذف غیرتصادفی اندک:** ۱۵۷ بزرگسالِ حذف‌شده کمی مسن‌تر و بیشتر مرد بودند.
6. **دقت تعداد نخ:** گرد کردن پاسخ‌ها (۱۰ و ۲۰ نخ) دقت این متغیر را کاهش می‌دهد و تحلیل شدت مصرف فقط روی ۱,۱۳۲ سیگاری فعلی امکان‌پذیر است.

گام‌های بعدی

- **فاز دوم:** تعریف رویدادها (خواب کوتاه، سیگاری فعلی)، احتمال‌های شرطی و مشترک، بررسی استقلال، مدل دوجمله‌ای و کوواریانس تعداد نخ و خواب.
- **فاز سوم:** فاصله‌ی اطمینان وزن‌دار، مقایسه‌ی دو گروه، آزمون فرض و تحلیل واریانس سه گروه همراه با اندازه‌ی اثر.
- **فاز چهارم:** رگرسیون خواب بر وضعیت سیگار با کنترل سن و جنسیت.
- **فاز پنجم:** تحلیل حساسیت (خواب روز کاری به‌جای میانگین هفتگی، حذف کدهای ۲ و ۱۴، آستانه‌ی دیگر برای خواب کوتاه) و در صورت امکان، مقایسه‌ی وضعیت سیگار خوداظهاری با کوتینین خون.

پیوست — بازتولیدپذیری

داده‌های خام در مخزن قرار ندارند. برای بازتولید همه‌ی نتایج این گزارش:

1. نصب کتابخانه‌ها: `pip install -r requirements.txt`
2. دریافت داده‌ها از CDC: `python src/download_data.py`
3. اجرای نوت‌بوک‌ها به ترتیب: `01_load_and_merge` (ادغام و جمعیت تحلیلی)، `02_data_quality` (بررسی کیفیت) و `03_descriptive_stats` (جدول‌ها و نمودارها).

منطق مشترک آماده‌سازی داده در `src/nhanes.py` قرار دارد تا نمونه‌ی تحلیلی در همه‌ی نوت‌بوک‌ها یکسان ساخته شود. جدول‌های این گزارش در `reports/phase1/` و نمودارها در `figures/` ذخیره شده‌اند.

منابع

- CDC/NCHS. National Health and Nutrition Examination Survey, August 2021 – August 2023: data files and documentation (DEMO_L, SLQ_L, SMQ_L).
- CDC/NCHS. NHANES August 2021 – August 2023: Brief Overview and Analytic Guidance.
- Watson NF, et al. Recommended amount of sleep for a healthy adult: a joint consensus statement of the American Academy of Sleep Medicine and Sleep Research Society. *Sleep*, 2015.
- Wonnacott TH, Wonnacott RJ. *Introductory Statistics*, 5th ed. Wiley.